

# **KLASIFIKASI Jenis Serat Kayu**

## **Nantu, Palapi, dan Uru**

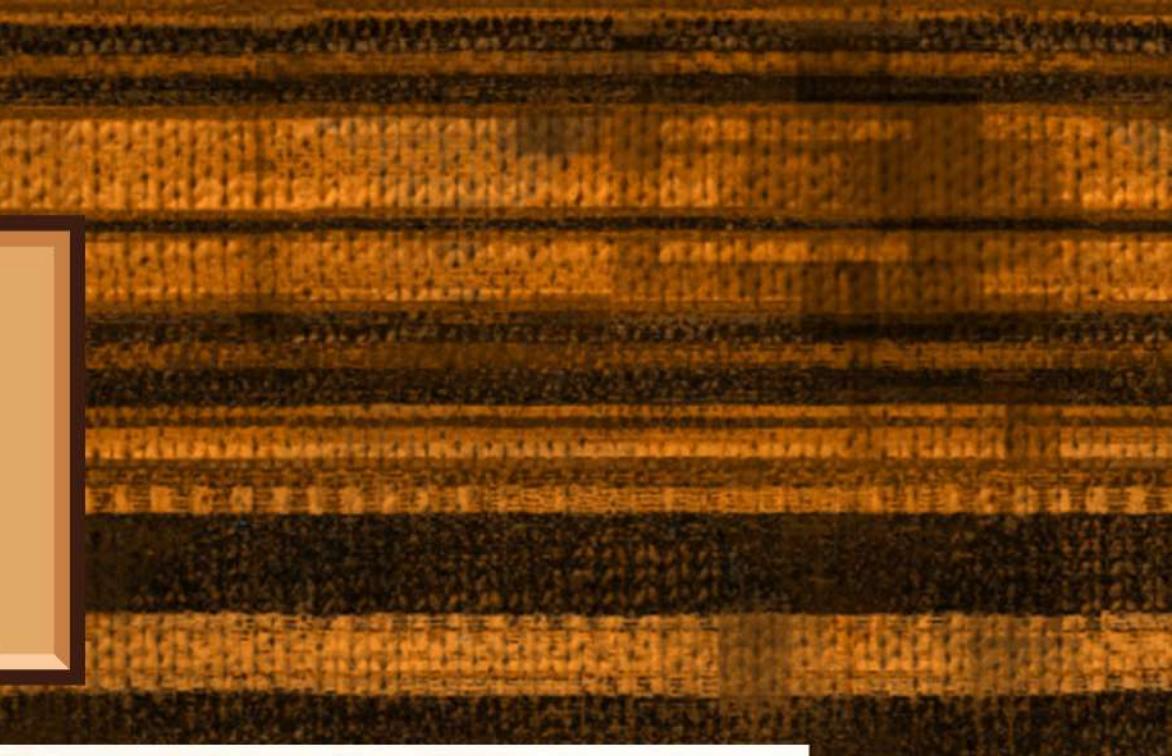
### **Menggunakan GLCM**

#### **Kelompok 8**





# ANGGOTA:



- **KAMILIA ROSADA: (F1D02310063)**
  - **SYA'BANUL MUKARAM: (F1D02310092)**
  - **WADIS FREANDLY: (F1D02310094)**
  - **LALU MUHAMMAD RIZALDI KURNIAWAN:(F1D02310120)**
- 

# LATAR BELAKANG

Proses identifikasi jenis kayu seperti Nantu, Palapi, dan Uru masih banyak dilakukan secara manual dengan melihat pola serat, warna, dan tekstur, padahal cara ini bersifat subjektif dan rawan kesalahan karena kemiripan tampilan ketiga jenis kayu tersebut. Ketiga jenis kayu ini dipilih karena sering digunakan dalam industri lokal namun sulit dibedakan tanpa keahlian khusus, sehingga cocok dijadikan objek pembanding untuk menguji kemampuan sistem klasifikasi dalam mengenali perbedaan halus antar jenis kayu yang mirip. Jenis kayu lain yang perbedaannya terlalu mencolok kurang relevan untuk pengujian ini, karena tidak memberikan tantangan yang sama.

Untuk mengatasi masalah identifikasi visual yang membingungkan, dibutuhkan sistem klasifikasi otomatis berbasis pengolahan citra digital yang bisa mengenali jenis kayu secara lebih konsisten. Salah satu metode yang digunakan adalah Gray Level Co-occurrence Matrix (GLCM), yang mampu mengekstrak ciri tekstur dari citra grayscale melalui analisis hubungan antar piksel, menghasilkan fitur seperti contrast, correlation, homogeneity, dan energy.

Dalam proyek ini, kami memanfaatkan dataset gambar serat kayu dari Kaggle, yang diproses mulai dari konversi ke grayscale, ekstraksi fitur tekstur dengan GLCM, hingga klasifikasi menggunakan algoritma machine learning seperti K-Nearest Neighbors (KNN), Support Vector Machine (SVM), dan Random Forest, dengan harapan sistem ini dapat membantu proses identifikasi kayu agar lebih mudah dilakukan dan mengurangi ketergantungan pada pengamatan manual.

# DESKRIPSI PROGRAM

**Program ini dibuat untuk mengklasifikasikan jenis kayu Nantu, Palapi, dan Uru berdasarkan citra serat kayu dengan proses preprocessing dan ekstraksi fitur. Gambar diresize ke  $256 \times 256$  piksel dan dikonversi ke grayscale untuk menyederhanakan data. Selanjutnya, dilakukan ekualisasi histogram untuk meningkatkan kontras, lalu dilakukan reduksi noise untuk menghilangkan gangguan atau bintik-bintik yang dapat mengacaukan analisis pola serat. Setelah itu, erosi diterapkan untuk mengurangi noise kecil, dan dilasi untuk mempertegas pola yang tersisa. Dari citra yang sudah diproses, fitur tekstur diekstrak menggunakan Gray Level Co-occurrence Matrix (GLCM) berupa contrast, correlation, homogeneity, dan energy. Fitur tersebut digunakan untuk melatih model machine learning seperti KNN, SVM, dan Random Forest agar dapat mengenali jenis kayu secara otomatis tanpa perlu keahlian khusus.**

# ' DATASET & LABEL '

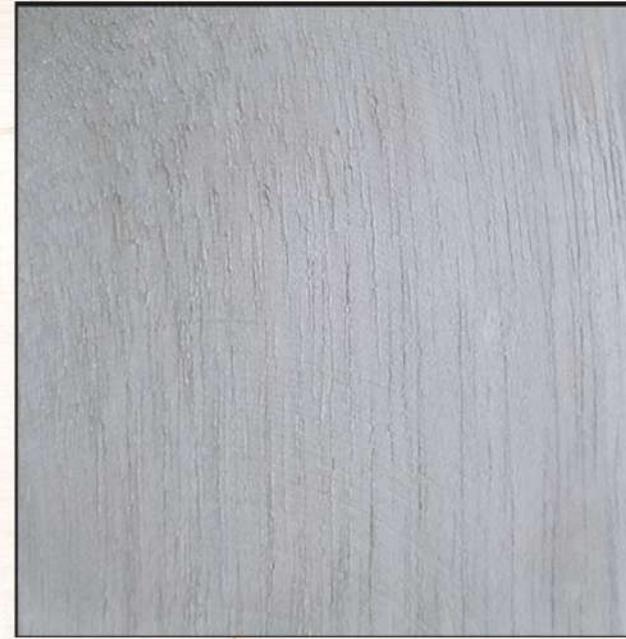
Nantu



Palapi



Uru



**Dataset yang digunakan dalam proyek ini berisi 1.269 citra serat kayu berformat JPG, yang terdiri dari tiga jenis kayu lokal, yaitu Nantu, Palapi, dan Uru. Setiap gambar sudah dilabeli berdasarkan jenis kayunya dan disusun dalam folder terpisah. Jumlah citra untuk masing-masing kelas seimbang, yaitu 423 gambar per jenis kayu. Dataset ini digunakan untuk melatih dan menguji sistem klasifikasi otomatis berbasis pengolahan citra dan machine learning dalam mengenali pola serat dari tiap jenis kayu tersebut.**

# TAHAP PREPROCESSING



# ANALISIS TANPA PREPROCESSING

-----Testing Set-----				
	precision	recall	f1-score	support
nantu	0.83	0.95	0.88	92
palapi	0.93	0.82	0.87	78
uru	0.90	0.86	0.88	84
accuracy			0.88	254
macro avg	0.89	0.87	0.88	254
weighted avg	0.88	0.88	0.88	254

```
[[87  2  3]
 [ 9 64  5]
 [ 9  3 72]]
Accuracy: 0.8779527559055118
```

Akurasi Random Forest: 87.8%

-----Testing Set-----				
	precision	recall	f1-score	support
nantu	0.91	0.88	0.90	92
palapi	0.82	0.69	0.75	78
uru	0.79	0.93	0.85	84
accuracy			0.84	254
macro avg	0.84	0.83	0.83	254
weighted avg	0.84	0.84	0.84	254

```
[[81  6  5]
 [ 8 54 16]
 [ 0  6 78]]
Accuracy: 0.8385826771653543
```

Akurasi SVM: 83.8%

-----Testing Set-----				
	precision	recall	f1-score	support
nantu	0.86	0.96	0.91	92
palapi	0.89	0.82	0.85	78
uru	0.90	0.86	0.88	84
accuracy			0.88	254
macro avg	0.88	0.88	0.88	254
weighted avg	0.88	0.88	0.88	254

```
[[88  2  2]
 [ 8 64  6]
 [ 6  6 72]]
Accuracy: 0.8818897637795275
```

Akurasi KNN: 88.2%

Tiga model klasifikasi diuji tanpa melakukan tahap preprocessing pada citra serat kayu. Model Random Forest mencapai akurasi sebesar 87.8%, SVM memperoleh 83.8%, dan KNN mencatat akurasi tertinggi yaitu 88.2%.

# ANALISIS PERCOBAAN 1

-----Testing Set-----				
	precision	recall	f1-score	support
nantu	0.83	0.91	0.87	92
palapi	0.87	0.85	0.86	78
uru	0.84	0.77	0.81	84
accuracy			0.85	254
macro avg	0.85	0.84	0.85	254
weighted avg	0.85	0.85	0.85	254

[[84 2 6]
[ 6 66 6]
[11 8 65]]

```
Accuracy: 0.8464566929133859
```

Akurasi Random Forest: 84.6%

-----Testing Set-----				
	precision	recall	f1-score	support
nantu	0.83	0.89	0.86	92
palapi	0.91	0.82	0.86	78
uru	0.81	0.82	0.82	84
accuracy			0.85	254
macro avg	0.85	0.84	0.85	254
weighted avg	0.85	0.85	0.85	254

[[82 1 9]
[ 7 64 7]
[10 5 69]]

```
Accuracy: 0.8464566929133859
```

Akurasi SVM: 84.6%

-----Testing Set-----				
	precision	recall	f1-score	support
nantu	0.85	0.89	0.87	92
palapi	0.93	0.88	0.91	78
uru	0.86	0.85	0.85	84
accuracy			0.87	254
macro avg	0.88	0.87	0.88	254
weighted avg	0.88	0.87	0.87	254

[[82 3 7]
[ 4 69 5]
[11 2 71]]

```
Accuracy: 0.8740157480314961
```

Akurasi KNN: 87.4%

Pada percobaan pertama, dilakukan tahapan preprocessing resize, grayscale, equalization, edge detection, dan reduce noise. Model Random Forest dan SVM sama-sama memperoleh akurasi sebesar 84.6%, sementara KNN kembali mencatatkan akurasi tertinggi sebesar 87.4%. Hasil ini menunjukkan bahwa preprocessing berkontribusi dalam meningkatkan keakuratan klasifikasi citra serat kayu.

# ANALISIS PERCOBAAN 2

-----Testing Set-----					-----Testing Set-----					-----Testing Set-----				
	precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support
nantu	0.84	0.88	0.86	92	nantu	0.80	0.89	0.84	92	nantu	0.83	0.91	0.87	92
palapi	0.85	0.87	0.86	78	palapi	0.85	0.74	0.79	78	palapi	0.87	0.79	0.83	78
uru	0.96	0.89	0.93	84	uru	0.95	0.94	0.95	84	uru	0.95	0.93	0.94	84
accuracy			0.88	254	accuracy			0.86	254	accuracy			0.88	254
macro avg	0.89	0.88	0.88	254	macro avg	0.87	0.86	0.86	254	macro avg	0.89	0.88	0.88	254
weighted avg	0.88	0.88	0.88	254	weighted avg	0.87	0.86	0.86	254	weighted avg	0.88	0.88	0.88	254
[[81 8 3] [10 68 0] [ 5 4 75]]					[[82 6 4] [20 58 0] [ 1 4 79]]					[[84 5 3] [15 62 1] [ 2 4 78]]				
Accuracy: 0.8818897637795275					Accuracy: 0.8622047244094488					Accuracy: 0.8818897637795275				

Akurasi Random Forest: 88.1%

Akurasi SVM: 86.2%

Akurasi KNN: 88.1%

Pada percobaan kedua, fungsi preprocessing ditambah dengan dilasi, erosi namun menghilangkan fungsi reduce noise. Hasilnya adalah model Random Forest dan KNN berhasil meraih akurasi tertinggi sebesar 88.1%, sedangkan SVM memperoleh akurasi sebesar 86.2%. Model KNN tetap konsisten memberikan hasil yang unggul, sementara Random Forest menunjukkan peningkatan akurasi dari percobaan sebelumnya.

# ANALISIS PERCOBAAN 3

-----Testing Set-----				
	precision	recall	f1-score	support
nantu	0.91	0.90	0.91	92
palapi	0.86	0.90	0.88	78
uru	0.93	0.90	0.92	84
accuracy			0.90	254
macro avg	0.90	0.90	0.90	254
weighted avg	0.90	0.90	0.90	254

```
[[83  7  2]
 [ 4 70  4]
 [ 4  4 76]]
Accuracy: 0.9015748031496063
```

Akurasi Random Forest: 90.1%

-----Testing Set-----				
	precision	recall	f1-score	support
nantu	0.87	0.89	0.88	92
palapi	0.97	0.94	0.95	78
uru	0.88	0.89	0.89	84
accuracy				254
macro avg	0.91	0.91	0.91	254
weighted avg	0.91	0.91	0.91	254

```
[[82  1  9]
 [ 4 73  1]
 [ 8  1 75]]
Accuracy: 0.905511811023622
```

Akurasi SVM: 90.5%

-----Testing Set-----				
	precision	recall	f1-score	support
nantu	0.86	0.92	0.89	92
palapi	0.97	0.94	0.95	78
uru	0.94	0.89	0.91	84
accuracy				254
macro avg	0.92	0.92	0.92	254
weighted avg	0.92	0.92	0.92	254

```
[[85  2  5]
 [ 5 73  0]
 [ 9  0 75]]
Accuracy: 0.9173228346456693
```

Akurasi KNN: 91.7%

Pada percobaan ketiga, fungsi preprocessing ditambahkan dengan reduce noise sehingga seluruh model mengalami peningkatan performa yang cukup signifikan dibandingkan percobaan sebelumnya. Model KNN mencatatkan akurasi tertinggi sebesar 91.7%, diikuti oleh SVM dengan 90.5%, dan Random Forest sebesar 90.1%. Model KNN menunjukkan hasil paling konsisten dan unggul dalam hal presisi, recall, dan f1-score, khususnya pada kelas palapi dan uru.



# Kesimpulan

Program ini dirancang untuk mempermudah klasifikasi jenis kayu berbasis tekstur dengan menggunakan citra kayu sebagai data masukan. Program ini memanfaatkan teknik pra-pemrosesan citra seperti konversi grayscale, resizing, ekualisasi histogram, dan normalisasi untuk meningkatkan kualitas data sebelum dilakukan ekstraksi fitur menggunakan metode **GLCM** (Gray Level Co-occurrence Matrix). Berdasarkan hasil evaluasi empat percobaan yang kami lakukan, percobaan ketiga menunjukkan performa akurasi terbaik dengan nilai 91,7% pada model KNN, diikuti oleh SVM dan Random Forest yang memperoleh akurasi masing-masing 90,5% dan 90,1%. Hal ini menunjukkan bahwa pemilihan parameter dan teknik pra-pemrosesan yang tepat dapat meningkatkan kualitas data latih dan data uji, serta menghasilkan model klasifikasi yang lebih akurat. Hasil evaluasi juga menunjukkan bahwa percobaan pertama menghasilkan akurasi terendah karena parameter pra-pemrosesan yang digunakan tidak mampu mempertahankan detail pola tekstur kayu, sedangkan percobaan kedua dan ketiga berhasil menyesuaikan parameter sehingga informasi penting tetap terjaga dan noise berkurang.

# Thank You

